

Міністерство освіти і науки України
Національний технічний університет України
Київський політехнічний інститут імені Ігоря Сікорського
Навчально-науковий фізико-технічний інститут

Симетрична криптографія
Комп'ютерний практикум №1

Експериментальна оцінка ентропії на символ джерела відкритого тексту

Виконали:
Медведцький Костянтин ФІ-04
Сковрон Роман ФІ-04

Київ 2023

Мета роботи

Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Порядок виконання роботи

0. Уважно прочитати методичні вказівки до виконання комп'ютерного практикуму.
1. Написати програми для підрахунку частот букв і частот біграм в тексті, а також підрахунку H_1 та H_2 за безпосереднім означенням. Підрахувати частоти букв та біграм, а також значення H_1 та H_2 на довільно обраному тексті російською мовою достатньої довжини (щонайменше 1Мб), де імовірності замінити відповідними частотами. Також одержати значення H_1 та H_2 на тому ж тексті, в якому вилучено всі пробіли.
2. За допомогою програми CoolPinkProgram оцінити значення $H(10)$, $H(20)$, $H(30)$.
3. Використовуючи отримані значення ентропії, оцінити надлишковість російської мови в різних моделях джерела.

Хід роботи

Для роботи було обрано твір “Війна і мир”

- 1.1 Кількість та частота літер, якщо вважати, що пробіл не входить до алфавіту:

Monograms without spaces:	Monogram frequency without spaces:
о: 265208	о: 11.540391238792298 %
е: 189292	е: 8.236945108644807 %
а: 188236	а: 8.190993805712148 %
и: 155955	и: 6.786302508392858 %
н: 148899	н: 6.479264256979181 %
т: 134701	т: 5.861445507890265 %
с: 122484	с: 5.329828966291499 %
л: 115273	л: 5.016045968708729 %
в: 106328	в: 4.6268088430149446 %
р: 101767	р: 4.4283392476779575 %
к: 77272	к: 3.3624517805042027 %
д: 70457	д: 3.0659005215211796 %
м: 68117	м: 2.9640766116135824 %
у: 62557	у: 2.722136039354506 %
п: 60520	п: 2.6334970203452004 %
я: 50591	я: 2.2014416351005295 %
ь: 45777	ь: 1.9919628734359258 %
г: 45263	г: 1.9695964248493854 %
ы: 44514	ы: 1.9370040707806717 %
б: 39977	б: 1.7395788232376086 %
з: 39387	з: 1.7139052733036417 %
ч: 33218	ч: 1.4454643757737422 %
й: 25743	й: 1.1201935524578073 %
ж: 24497	ж: 1.0659744961565827 %
ш: 21319	ш: 0.92768544244447 %
х: 19779	х: 0.8606731256676754 %
ю: 14108	ю: 0.6139024448617001 %
ц: 8280	ц: 0.36029998890380466 %
э: 7050	э: 0.30677716446519604 %
щ: 6809	щ: 0.2962901720345418 %
ф: 4707	ф: 0.20482271108335856 %

1.2 Кількість та частота літер, якщо вважати, що пробіл входить до алфавіту:

Monograms with spaces:	Monogram frequency with spaces:
: 443926	: 16.189796466899658 %
о: 265208	о: 9.672025385747904 %
е: 189292	е: 6.903400460464966 %
а: 188236	а: 6.864888579950993 %
и: 155955	и: 5.687613944655948 %
н: 148899	н: 5.430284561221672 %
т: 134701	т: 4.912489410144598 %
с: 122484	с: 4.466940504615043 %
л: 115273	л: 4.203958335688661 %
в: 106328	в: 3.8777379084183106 %
р: 101767	р: 3.711400136615061 %
к: 77272	к: 2.8180776809429284 %
д: 70457	д: 2.5695374672092854 %
м: 68117	м: 2.4841986410703676 %
у: 62557	у: 2.281427755030888 %
п: 60520	п: 2.2071392127894454 %
я: 50591	я: 1.845032715040166 %
ь: 45777	ь: 1.6694681385304433 %
г: 45263	г: 1.6507227724469375 %
ы: 44514	ы: 1.6234070541657202 %
б: 39977	б: 1.4579445523741517 %
з: 39387	з: 1.436427497920322 %
ч: 33218	ч: 1.2114466353344315 %
й: 25743	й: 0.9388364962795555 %
ж: 24497	ж: 0.8933953948397726 %
ш: 21319	ш: 0.7774950574596527 %
х: 19779	х: 0.7213318983767752 %
ю: 14108	ю: 0.5145128885332699 %
ц: 8280	ц: 0.30196815403001664 %
э: 7050	э: 0.25711056593135473 %
щ: 6809	щ: 0.24832139623072264 %
ф: 4707	ф: 0.17166233104097686 %

1.3 Кількість та частота біграм без перетинів та без пробілів:

BiGram with no crossing and no spaces:	Bigram frequency without spaces and crossing:
то: 20216	то: 1.7593786824154383 %
ст: 15511	ст: 1.349907140034916 %
на: 14404	на: 1.2535660141230693 %
ов: 13299	ов: 1.1573989462526173 %
ал: 12369	ал: 1.0764619570041827 %
ос: 12203	ос: 1.0620151395684405 %
го: 12131	го: 1.055749050078239 %
не: 12110	не: 1.053921440643597 %
но: 12040	но: 1.0478294091947902 %
он: 11915	он: 1.0369507816076349 %
ен: 11781	ен: 1.0252888928342045 %
по: 11644	по: 1.0133659169986824 %
ко: 11570	ко: 1.0069257694670863 %
ра: 11163	ра: 0.971504958043309 %
от: 11013	от: 0.9584506049387228 %
ни: 11010	ни: 0.9581895178766311 %
во: 10686	во: 0.9299921151707249 %
ка: 9741	ка: 0.8477496906118314 %
ол: 9526	ол: 0.8290384511619244 %
ло: 9404	ло: 0.818420910636861 %
ер: 9262	ер: 0.8060627896978527 %
ла: 9218	ла: 0.8022335127871739 %
ли: 9174	ли: 0.7984042358764953 %
ор: 9072	ор: 0.7895272757653768 %
ро: 9014	ро: 0.7844795925649368 %
ел: 8673	ел: 0.7548026965071772 %
ан: 8663	ан: 0.7539324063002049 %
пр: 8496	пр: 0.7393985598437655 %
ре: 7911	ре: 0.6884865827358791 %
од: 7637	од: 0.6646406310648348 %
та: 7599	та: 0.6613335282783397 %

1.4 Кількість та частота біграм з перетинами, але без пробілів:

BiGram with crossing and without spaces:	Bigram frequency with crossing and without spaces:
то: 40383	то: 1.757246471408356 %
ст: 31163	ст: 1.3560426859940717 %
на: 28685	на: 1.2482137293501891 %
ов: 26796	ов: 1.1660148193016444 %
ал: 24581	ал: 1.0696301788794491 %
го: 24389	го: 1.0612753928925138 %
не: 24252	не: 1.0553139049747529 %
ос: 24107	ос: 1.049004300974203 %
но: 24062	но: 1.047046148008515 %
ен: 23647	ен: 1.0289876262138373 %
он: 23634	он: 1.0284219375793051 %
по: 23274	по: 1.0127567138538016 %
ко: 23103	ко: 1.0053157325841875 %
ра: 22360	ра: 0.9729844513951622 %
ни: 21891	ни: 0.9525761460416591 %
от: 21889	от: 0.9524891170209617 %
во: 21300	во: 0.9268590704256242 %
ка: 19484	ка: 0.8478367196325286 %
ол: 19141	ол: 0.8329112425829517 %
ер: 18775	ер: 0.8169849317953565 %
ло: 18707	ло: 0.8140259450916503 %
ла: 18483	ла: 0.8042786947735591 %
ли: 18198	ли: 0.7918770593242022 %
ор: 18154	ор: 0.7899624208688629 %
ро: 18131	ро: 0.7889615871308446 %
ел: 17340	ел: 0.7545416094450855 %
ан: 17235	ан: 0.7499725858584804 %
пр: 16821	пр: 0.7319575785741513 %
ре: 16024	ре: 0.6972765138263005 %
од: 15276	од: 0.6647276600855321 %

1.5 Кількість та частота біграм без перетинів, але з пробілами:

BiGram with no crossing and with spaces:	Bigram frequency with spaces and no crossing:
о : 29644	о : 2.16220947407194 %
и : 26048	и : 1.8999201315823062 %
е : 23013	е : 1.6785496770617174 %
а : 22764	а : 1.660387817695778 %
с : 21769	с : 1.5878133194262603 %
п : 21220	п : 1.5477697017881045 %
н : 21158	н : 1.5432474717451796 %
в : 20292	в : 1.4800821295327151 %
то : 19707	то : 1.437412700901893 %
о : 16425	о : 1.198026265403846 %
и : 15365	и : 1.1207107195086816 %
ст : 15358	ст : 1.1202001451489965 %
я : 14706	я : 1.0726437905040462 %
на : 14339	на : 1.0458751062177016 %
ь : 13522	ь : 0.9862837845230324 %
к : 13420	к : 0.9788439867104789 %
го : 12147	го : 0.8859923924420408 %
не : 12034	не : 0.8777502634928392 %
ал : 11978	ал : 0.8736656686153588 %
но : 11684	но : 0.8522215455085868 %
по : 11571	по : 0.8439794165593854 %
ра : 11139	ра : 0.8124696846473937 %
ко : 10988	ко : 0.8014558663170447 %
ов : 10450	ов : 0.7622145798155368 %
ни : 10429	ни : 0.7606828567364816 %
д : 10285	д : 0.7501796127658178 %
й : 10221	й : 0.7455115043344116 %
во : 10170	во : 0.7417916054281348 %

1.6 Кількість та частота біграм з перетинами та з пробілами:

BiGram with crossing and spaces:	Bigram frequency with spaces and crossing:
о : 59358	о : 2.1647623458703653 %
и : 52237	и : 1.9050623447762773 %
е : 46030	е : 1.6786955554501988 %
а : 45491	а : 1.6590384426023244 %
с : 43324	с : 1.5800088256425031 %
п : 42405	п : 1.546493265888892 %
н : 42402	н : 1.5463838570975306 %
в : 40699	в : 1.4842761332015566 %
то : 39604	то : 1.4443419243547617 %
о : 33019	о : 1.204189627317187 %
и : 30818	и : 1.1239200440552732 %
ст : 30406	ст : 1.1088945700416848 %
я : 29593	я : 1.0792447875828317 %
на : 28578	на : 1.0422281465056655 %
к : 26929	к : 0.9820897808541909 %
ь : 26912	ь : 0.9814697977031448 %
го : 24215	го : 0.8831112942695322 %
не : 24072	не : 0.8778961418813206 %
ал : 23882	ал : 0.8709669184284521 %
но : 23322	но : 0.8505439440410502 %
по : 23267	по : 0.8485381161994303 %
ра : 22261	ра : 0.8118497014963475 %
ко : 22145	ко : 0.8076192282303857 %
ни : 21069	ни : 0.7683779417288777 %

1.7 H1 та H2:

Entropy MonoGram without spaces: 4.459495560105348

Entropy MonoGram with spaces: 4.376343121574429

Entropy BiGram without spaces and crossing: 4.138908270465847

Entropy BiGram without spaces and with crossing: 4.138711256669181

Entropy BiGram with spaces and without crossing: 3.966535460585095

Entropy BiGram with spaces and crossing: 3.966562055656355

2. H(10)

Лабораторная работа №1

Произвольная часть текста:
_следующу

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Поле ввода символов:

Продолжить Другой

Неравенство для энтропии:
 $3,19338846685165 < H < 3,49302019244805$

Двоичная таблица угаданных символов:

00000000010000000000000000000000	▲
00100000000000000000000000000000	
10000000000000000000000000000000	
10000000000000000000000000000000	
10000000000000000000000000000000	▼

Вероятности:

$q[1] = 0,28$
$q[2] = 0,08$
$q[3] = 0,1$
$q[4] = 0,06$
$q[5] = 0,02$
$q[6] = 0,06$
$q[7] = 0$
$q[8] = 0$
$q[9] = 0$
$q[10] = 0,04$
$q[11] = 0,02$
$q[12] = 0$
$q[13] = 0$
$q[14] = 0$
$q[15] = 0$
$q[16] = 0,02$
$q[17] = 0$
$q[18] = 0,1$
$q[19] = 0,04$
$q[20] = 0,06$
$q[21] = 0$
$q[22] = 0$
$q[23] = 0,02$
$q[24] = 0$
$q[25] = 0$
$q[26] = 0,02$
$q[27] = 0,02$
$q[28] = 0,06$
$q[29] = 0$
$q[30] = 0$
$q[31] = 0$
$q[32] = 0$

Строка состояния:

$$R = 0.33137$$

H(20)

[illegible]

$$R = 0.44897$$

H(30)

Лабораторная работа №1

Произвольная часть текста:
то_им_следовало_подчиняться_г

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:

Символ по счету:

Номер эксперимента: 51

Неравенство для энтропии:
 $1,77327203440404 < H < 2,434034403112$

Двоичная таблица угаданных символов:

10000000000000000000000000000000
10000000000000000000000000000000
01000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000

Поле ввода символов:

Продолжить Другой

Вероятности:

$q[1] = 0,58$
$q[2] = 0,1$
$q[3] = 0,02$
$q[4] = 0,04$
$q[5] = 0,04$
$q[6] = 0$
$q[7] = 0$
$q[8] = 0,02$
$q[9] = 0$
$q[10] = 0$
$q[11] = 0,04$
$q[12] = 0$
$q[13] = 0$
$q[14] = 0$
$q[15] = 0$
$q[16] = 0$
$q[17] = 0$
$q[18] = 0,02$
$q[19] = 0$
$q[20] = 0,02$
$q[21] = 0$
$q[22] = 0$
$q[23] = 0,02$
$q[24] = 0$
$q[25] = 0,02$
$q[26] = 0$
$q[27] = 0,04$
$q[28] = 0,02$
$q[29] = 0$
$q[30] = 0,02$
$q[31] = 0$
$q[32] = 0$

Строка состояния:

$R = 0.57928$

Висновок

Виконую цю лабораторну роботу, ми дізналися про існування російської мови. Також виявилось, що у творі “Війна і мир” майже половина символів - це розділові знаки, латиниця та цифри. Тим самим з трохи більше 5 мільйонів символів оригінального тексту, після обробки, у нас залишилось приблизно 2.3 мільйони символів кирилиці.